北京交通大學
BEIJING JIAOTONG UNIVERSITY

融合Mamba与跨序列注意力的时空交通流预测研究

汇报人： 倪矗

指导老师： 黄惠芳

目录

CONTENTS

01 研究背景

02 研究现状

03 研究内容

04 研究基础

05 后期计划

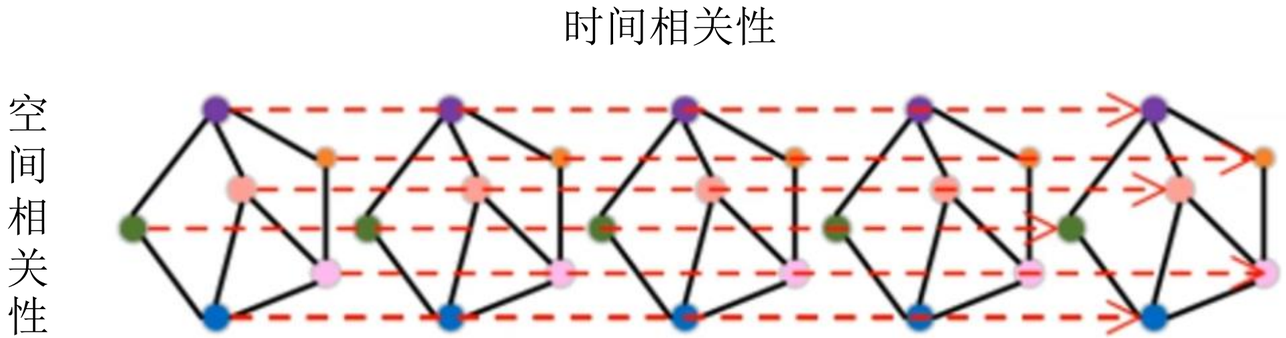
研究意义

随着智慧城市建设的发展，交通预测逐渐成为智能交通系统（ITS）中的核心任务之一。通过对道路网络中各节点的交通流量、速度或需求进行准确预测，城市管理者能够优化信号控制、缓解拥堵、提升公共交通效率。



时空依赖

- **时间相关性：**交通流量受不同时间段（如早晚高峰）、工作日与周末节假日、以及突发事件的影响，存在着多个方面的时间相关性因素。
- **空间相关性：**所有的收费站点与连接收费站点的高速公路构成一个网状拓扑关系，也就是说网中的所有站点存在着空间相关性。



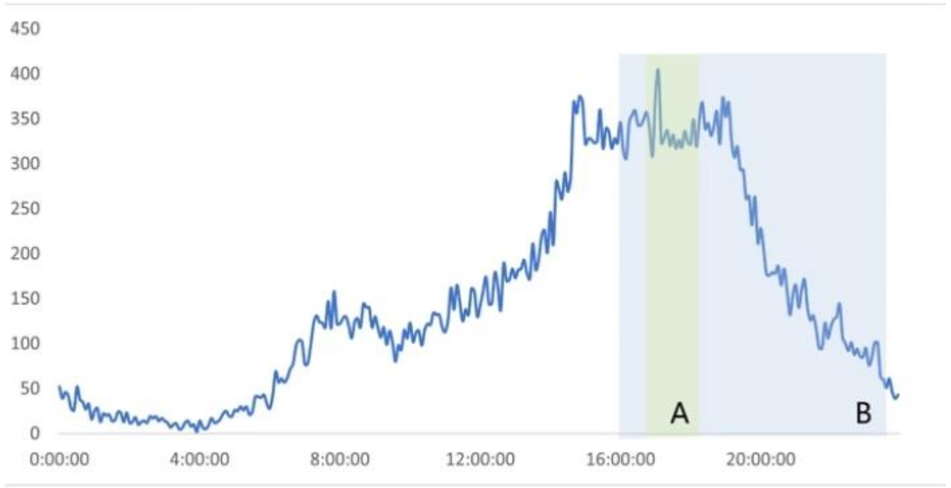
交通流量数据的时空相关性

时间序列特性

北京交通大学 BEIJING JIAOTONG UNIVERSITY

时间序列数据的特性：时间序列数据在进行下采样后，仍然能够保留重要的时间关系，这一点与许多其他类型的序列数据不同。

多尺度时间依赖：时空数据在不同尺度下，存在着不同的时空相关性，交通流量预测建模需要考虑多尺度下的时间和空间特征。

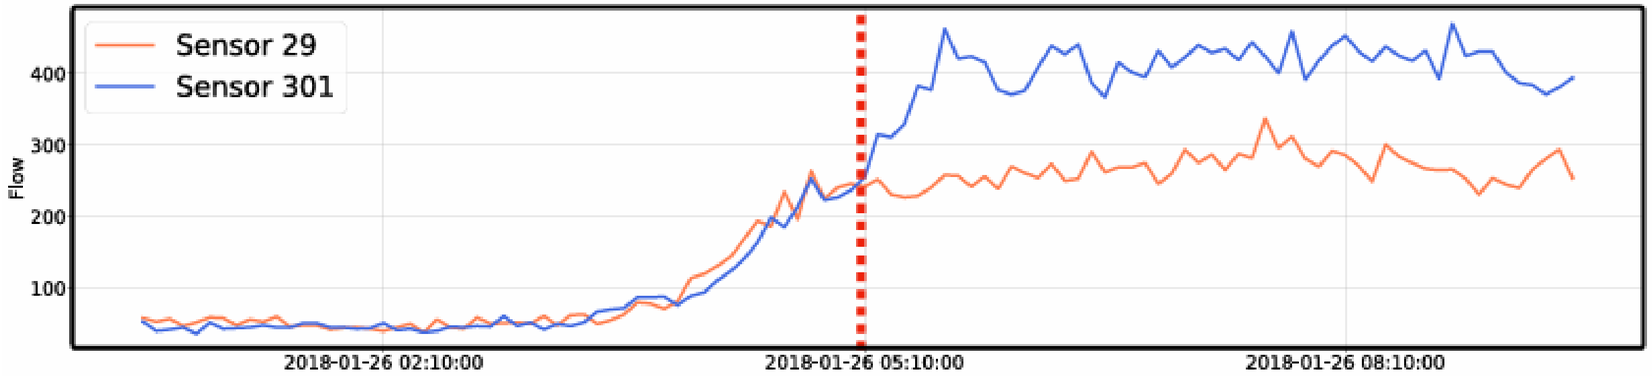


不同时间尺度上呈现不同的交通流量趋势

空间异质性

北京交通大学 BEIJING JIAOTONG UNIVERSITY

空间异质性：不同空间位置（如城市区域、道路节点）在结构、功能、交通模式等方面存在显著差异，从而导致交通流量的统计特征和变化规律在不同区域呈现不同的表现形式。



若忽略空间异质性，不同区域的节点会被错误地认为具有相同交通规律，从而严重影响预测精度。

研究分析

北京交通大学 BEIJING JIAOTONG UNIVERSITY

多尺度时间依赖建模

如何在时间序列下采样后充分利用保留的趋势性、周期性等全局信息，实现多尺度的深层时间依赖建模?

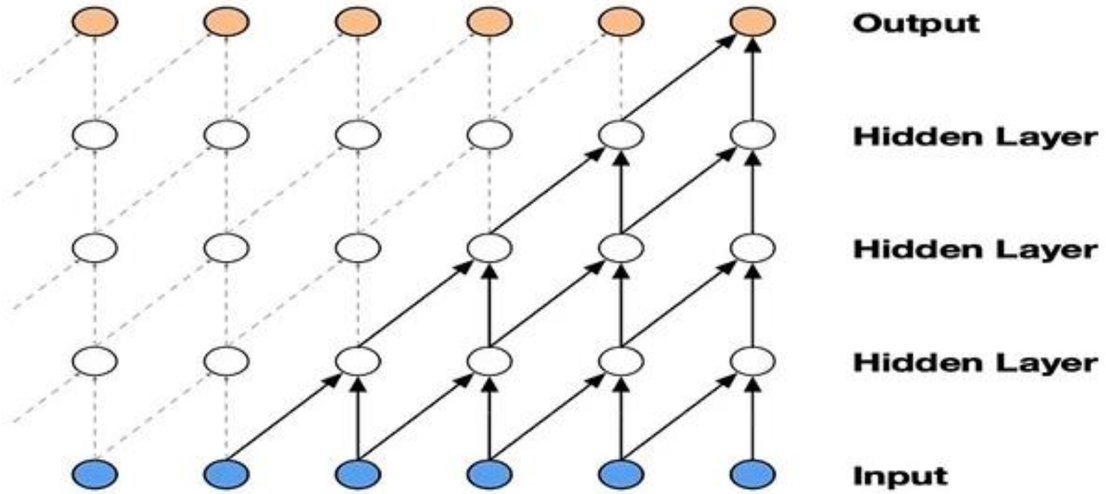
考虑空间异质性建模

如何在构建动态图结构时有效考虑每个节点因空间异质性导致的不同的局部时空模式?

多尺度时间依赖建模

北京交通大学 BEIJING JIAOTONG UNIVERSITY

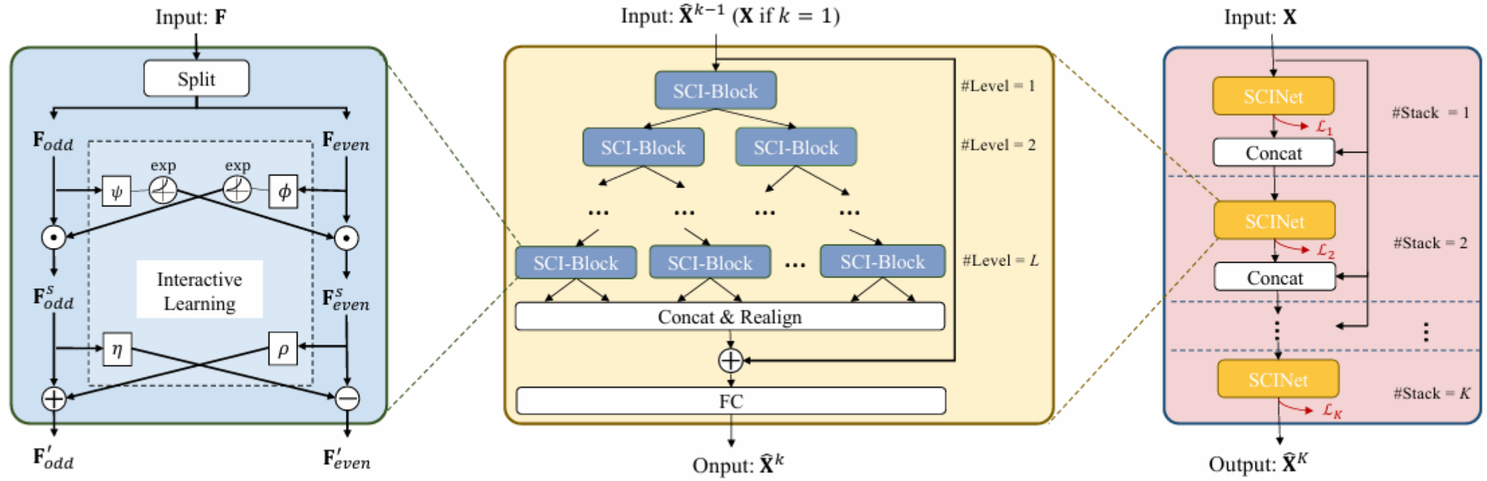
基于TCN及其变体的模型： TCN采用因果卷积，确保输出不依赖于未来数据，但卷积操作本身可以在整个序列上并行进行，极大提升了训练效率。



痛点：TCN的感受野是预先设定的、僵化的，无法适应数据中动态变化的依赖关系。

多尺度时间依赖建模

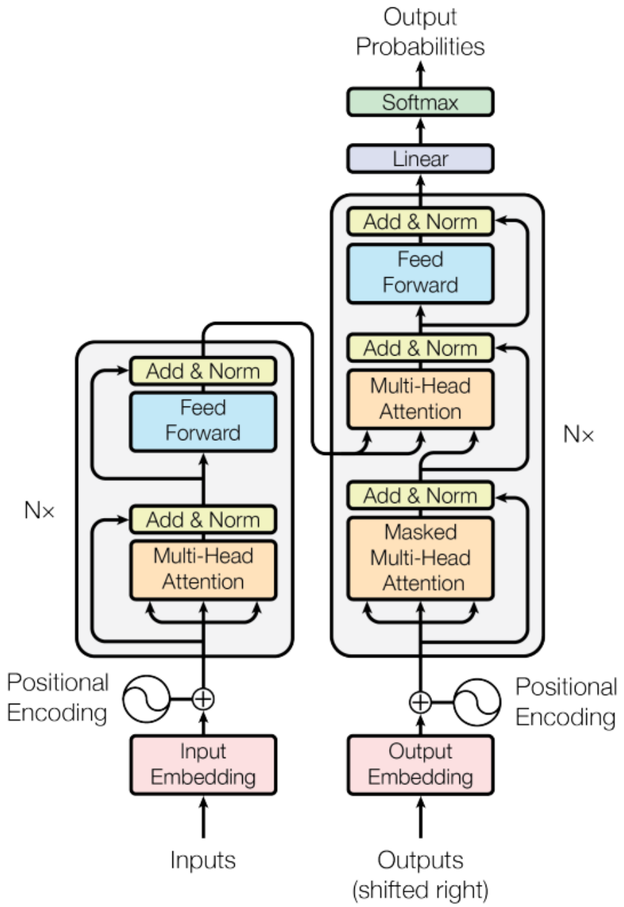
基于交互学习的时间序列模型：SCINet它的目的是在将时间序列下采样为两个子序列（奇数和偶数位置）后，弥补因下采样可能造成的信息损失，并通过两个子序列之间的信息交换来增强特征的表达能力。



多尺度时间依赖建模

北京交通大学 BEIJING JIAOTONG UNIVERSITY

基于tansformer的时序预测模型：能够完美捕捉时间序列中的长期依赖，自注意力机制允许序列中任意两个时间点直接交互，无视距离。克服了RNN的梯度消失和TCN感受野有限的根本性问题。

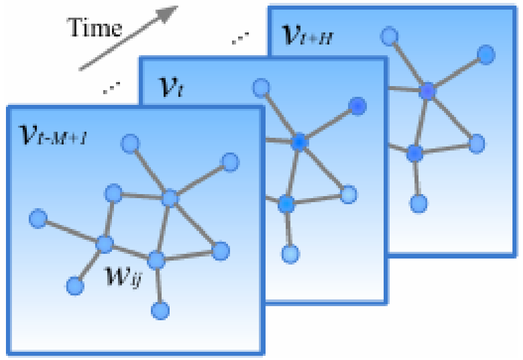


痛点：$O(N^2)$ 计算与内存复杂度自注意力需要计算所有时间点两两之间的关联。当历史序列长度 N 增加时，计算和内存开销呈平方级增长。

考虑空间异质性建模

北京交通大学 BEIJING JIAOTONG UNIVERSITY

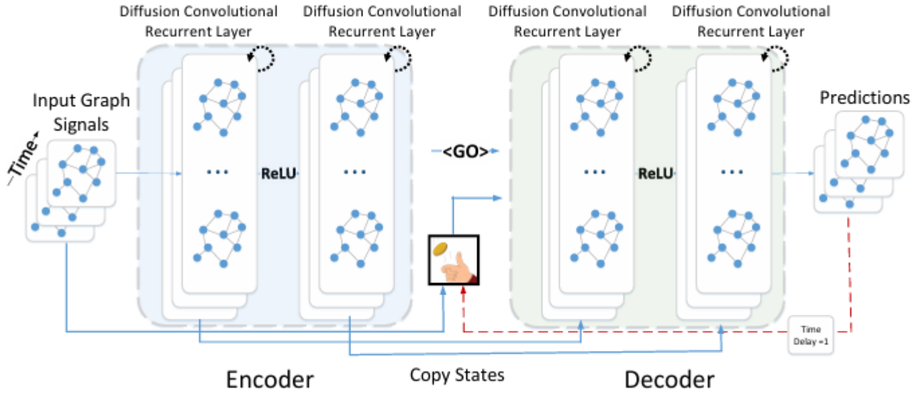
STGCN：将路网建模为图，使用卷积来捕捉空间依赖。



$$L = I_n - D^{-\frac{1}{2}} W D^{-\frac{1}{2}}$$

静态图结构W在整个训练和预测过程中是固定不变的无法反映交通状况随时间动态变化的关系

DCRNN：将空间依赖的传播视为一个**扩散过程**，并利用RNN来建模动态时空依赖。

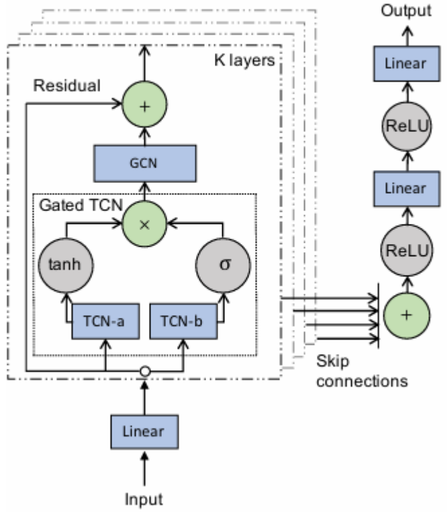


$$\boldsymbol{X}_{:,p} \star_{\mathcal{G}} f_{\boldsymbol{\theta}} = \sum_{k=0}^{K-1} \left(\theta_{k,1} \left(\boldsymbol{D}_O^{-1} \boldsymbol{W} \right)^k + \theta_{k,2} \left(\boldsymbol{D}_I^{-1} \boldsymbol{W}^\intercal \right)^k \right) \boldsymbol{X}_{:,p} \quad \text{for } p \in \{1, \cdots, P\}$$

尽管扩散过程是双向的，但其基础的图结构仍然是静态的，无法适应动态变化的空间关系。

考虑空间异质性建模

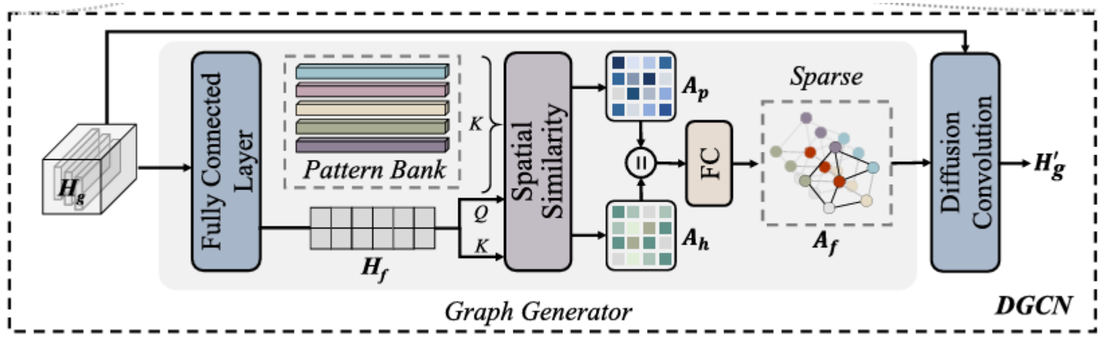
Graph WaveNet：通过结合自适应邻接矩阵和空洞时序卷积，同时解决空间依赖的未知性和时间依赖的长程性。



$$\tilde{\mathbf{A}}_{adp} = SoftMax(ReLU(\mathbf{E}_1\mathbf{E}_2^T)).$$

虽然 $\tilde{\mathbf{A}}_{adp}$ 是自适应的，但它是一个全局共享的、训练完成后固定的矩阵。它无法根据不同的时间上下文或交通状况进行动态调整。

STIDGCN：明确地动态化图结构，以更好地反映随时间演化的空间依赖关系。



$$\mathbf{A}_p = \frac{\exp\left(\boldsymbol{H}_f^\top[\ldots,i]\boldsymbol{\Phi}[\ldots,j]\right)}{\sum_{j=1}^{N}\exp\left(\boldsymbol{H}_f^\top[\ldots,i]\boldsymbol{\Phi}[\ldots,j]\right)},$$

$$\mathbf{A}_h = \frac{\exp\left(\boldsymbol{H}_f^\top[\ldots,i]\boldsymbol{H}_f[\ldots,j]\right)}{\sum_{j=1}^{N}\exp\left(\boldsymbol{H}_f^\top[\ldots,i]\boldsymbol{H}_f[\ldots,j]\right)},$$

问题提出

1. 时间建模的局限性
   1. TCN感受野固定，难以捕捉**长期周期**与**多尺度时间依赖**；
   2. Transformer虽能建模全局依赖，但存在**$O(N^2)$复杂度**，难以适用于长序列交通数据。

Mamba-TCN长序列时间模块

2. 空间建模的不足
   1. 现有图结构多为**静态或全局固定**，无法适应**动态变化的交通模式**；
   2. 缺乏对**空间异质性**的显式建模，导致不同区域节点的局部特征被忽略。

动态图门控融合模块

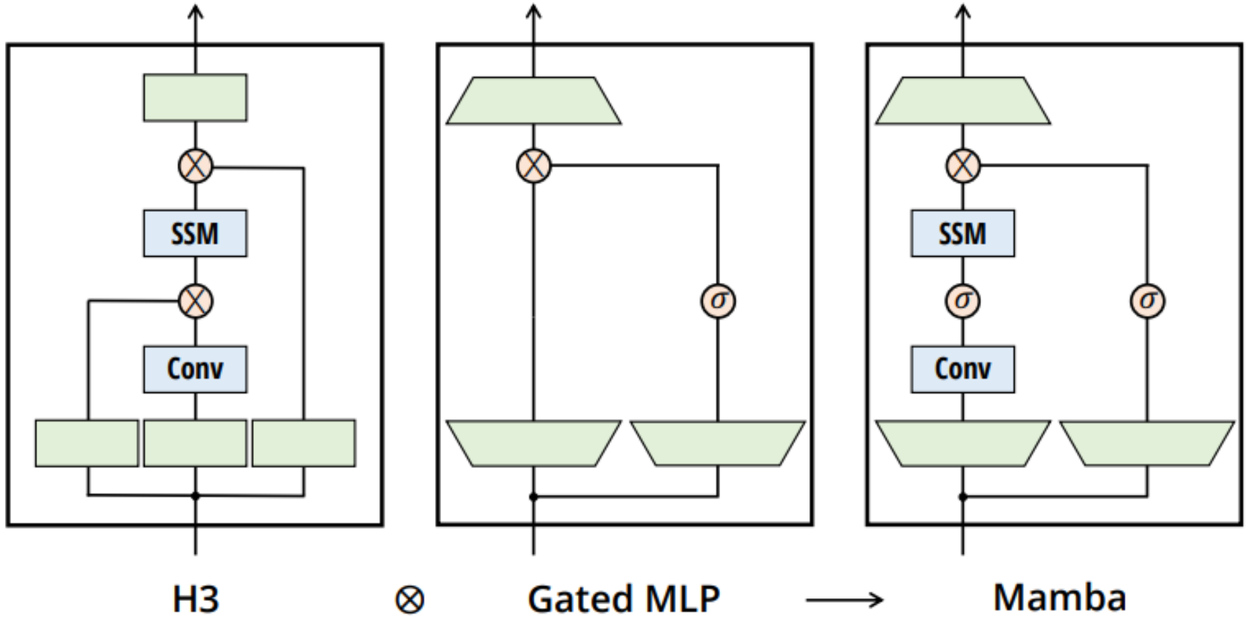
3. 多尺度时序交互机制缺失
   1. 传统下采样方法未能有效保留与交互**多分辨率时序特征**；
   2. 缺乏能够**动态融合局部与全局时空特征**的灵活架构。

跨序列注意力增强的 CA-STI 模块

构建 Mamba-TCN长序列时间模块

北京交通大学 BEIJING JIAOTONG UNIVERSITY

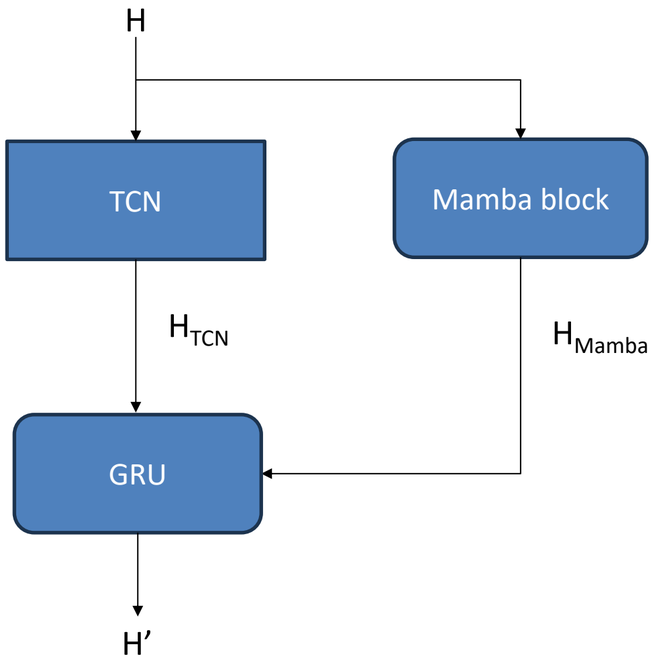
- TCN：感受野有限且静态，难以捕捉**长期周期**。
- Transformer：全局依赖建模能力强，但O(N²)复杂度无法承受**交通长序列**。
- Mamba：状态空间模型（SSM）提供**线性复杂度**与**全局感受野**。



构建 Mamba-TCN长序列时间模块

北京交通大学 BEIJING JIAOTONG UNIVERSITY

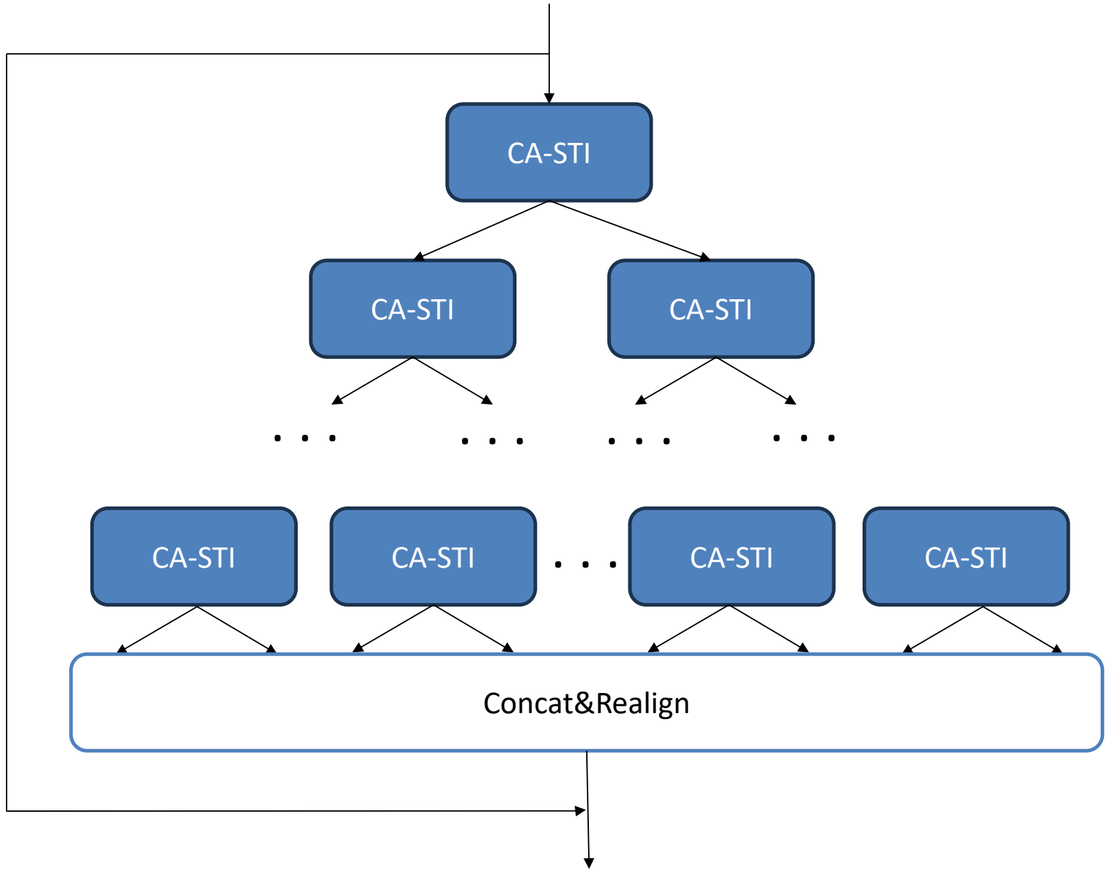
- **TCN分支**：通过空洞卷积堆栈，专注捕捉局部波动与短期趋势。
- **Mamba分支**：通过状态空间模型与选择性机制，有效建模长期周期与全局依赖。
- **自适应门控融合**：根据当前交通模式，动态混合两条通路的信号
  - 动态生成门控权重：$G = \sigma(W \cdot [H_{TCN} || H_{Mamba}])$
  - 自适应加权融合：$H' = G \odot H_{TCN} + (1 - G) \odot H_{Mamba}$



跨序列注意力增强的 CA-STI 模块

多分辨率特征提取：通过递归地将时间序列下采样成子序列，可以获得多个分辨率的动态时间特征。

现有方法的局限性：传统的时间序列预测方法，如RNN、基于Transformer的模型和时间卷积网络（TCN），尽管取得了一定的成功，但它们并没有充分利用时间序列在下采样后保留的时间关系的特性。



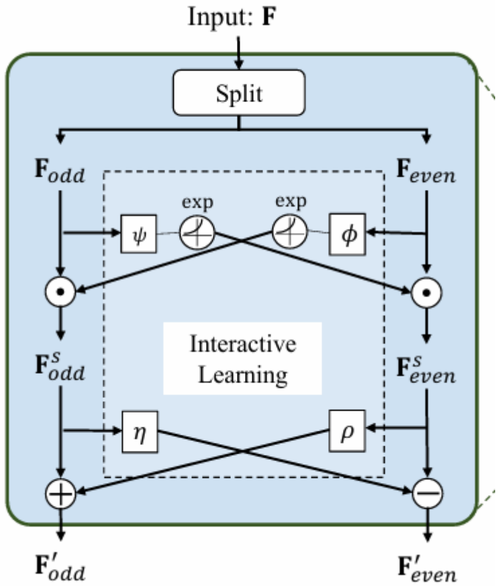
跨序列注意力增强的 CA-STI 模块

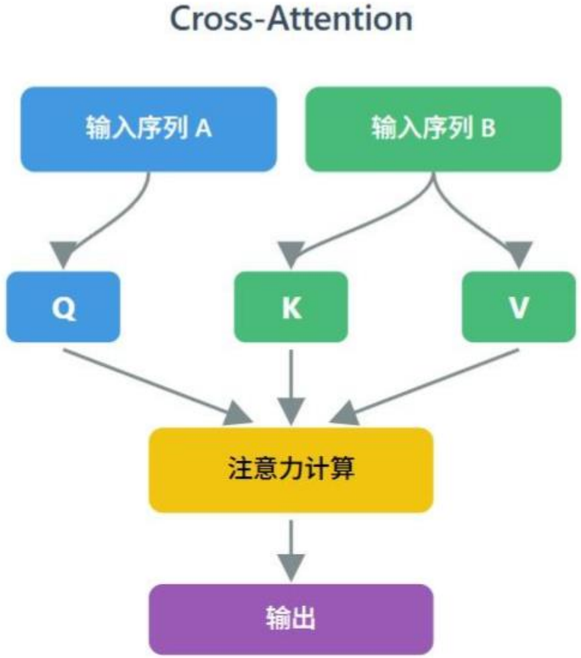
北京交通大学 BEIJING JIAOTONG UNIVERSITY

弥补信息损失：在下采样过程中可能会丢失部分信息，因此需要一种机制来补偿这种信息损失，这可以通过在不同子序列之间进行**交互学习**来实现。

Hadamard乘积：是一种**静态、局部且内容无关**的交互方式。

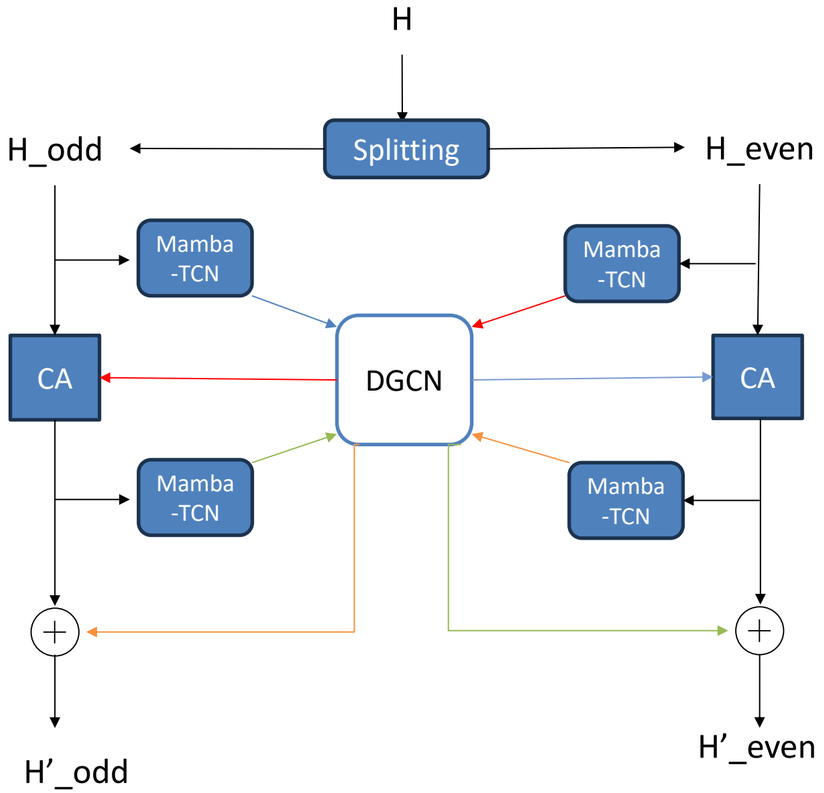
交叉注意力：是一种**动态、全局、内容感知**的模型可以**自主决定**在交互时应该关注什么，忽略什么。





跨序列注意力增强的 CA-STI 模块

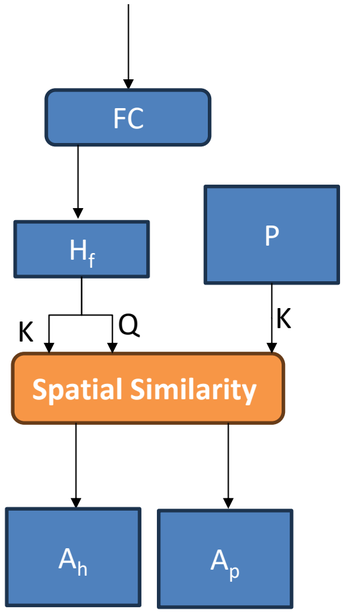
- 给定 odd 子序列特征 $H_o \in \mathbb{R}^{T/2\times N\times d}$，even 子序列特征 $H_e \in \mathbb{R}^{T/2\times N\times d}$。
- （1）构建 Query/Key/Value
- $Q_o = H_o W_Q, K_e = H_e W_K, V_e = H_e W_V$
- $Q_e = H_e W'_Q, K_o = H_o W'_K, V_o = H_o W'_V$
- （2）Odd → Even 的 Cross Attention
- $Attn_{o\leftarrow e} = softmax\left(\frac{Q_o K_e^{\top}}{\sqrt{d}}\right) V_e$
- （3）Even → Odd 的 Cross Attention
- $Attn_{e\leftarrow o} = softmax\left(\frac{Q_e K_o^{\top}}{\sqrt{d}}\right) V_o$
- （4）融合方式
- $H'_o = H_o + Attn_{o\leftarrow e}$
- $H'_e = H_e + Attn_{e\leftarrow o}$



动态图门控融合模块

自适应邻接矩阵：一个可学习的嵌入矩阵，存储每个节点由于空间异质性而形成的独特交通模式。

Spatial Similarity 模块：计算交通网络中不同节点之间在空间上的关联程度。



A_p：这是一个可训练的、与输入数据无关的矩阵，它通过模型训练逐渐学习到每个节点由于空间异质性产生的交通模式。

A_h：节点自身表示的相似性，这个注意力基于它们当前状态的相似度。

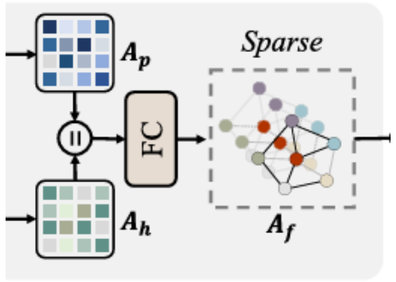
$$A_h[i,j] = \frac{\exp\left(H_f[:,i]^\top \cdot H_f[:,j]\right)}{\sum_{j=1}^{N} \exp\left(H_f[:,i]^\top \cdot H_f[:,j]\right)}$$

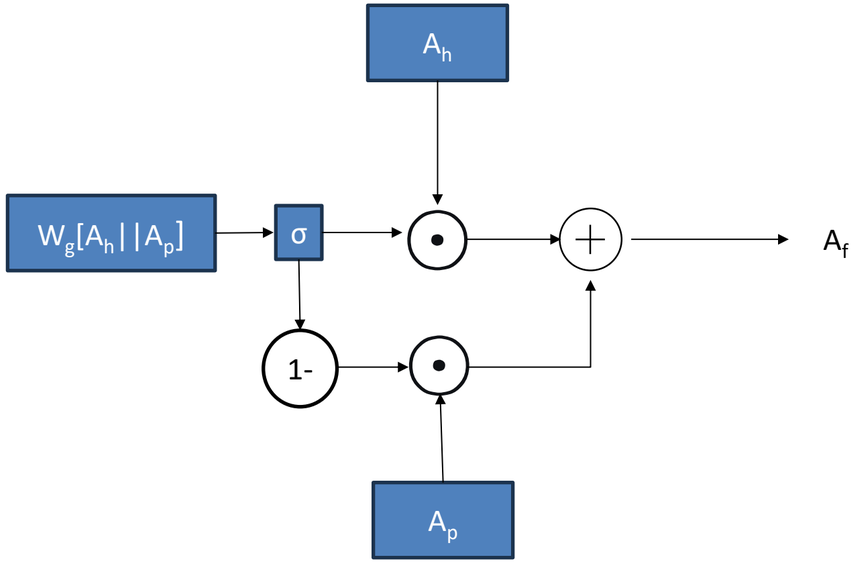
$$A_p[i,j] = \frac{\exp\left(H_f[:,i]^\top \cdot \mathcal{P}[:,j]\right)}{\sum_{j=1}^{N} \exp\left(H_f[:,i]^\top \cdot \mathcal{P}[:,j]\right)}$$

动态图门控融合模块

直接拼接：将静态图和动态图简单地放在一起，它们可能包含**重复或矛盾**的信息。模型需要自行过滤和化解这些冲突，这在实践中非常困难，容易导致学习不稳定或性能下降。

门控融合：通过显式的门控机制，结构化地处理了这种冲突。它不是在特征层面简单叠加，而是在表示层面进行加权抉择。





$$A_f = \sigma(W_g[A_h \| A_p]) \odot A_h + (1 - \sigma(W_g[A_h \| A_p])) \odot A_p$$

实验环境

北京交通大学 BEIJING JIAOTONG UNIVERSITY

开发环境

- 编程语言：Python 3.8+
- 深度学习框架：PyTorch 2.0
- GUP：NVIDIA RTX 5060

公开数据集

- 加州高速公路 PeMS04/PeMS08

数据集	PeMS04	PeMS08
节点数	307	170
边数	340	295
时间步	16992	17856
时间间隔	5min	5min
时间范围	2018.1.1-2018.2.28	2016.7.1-2016.8.31

模型评估

- MAE（平均绝对误差）：它是真值与预测值之差的平均值，衡量绝对偏差。

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i^{real} - y_i^{pred}\right|$$

- RMSE（均方根误差）：也被称为标准差，它是真值与预测值误差平方的平均 值，类似标准差。

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i^{real} - y_i^{pred})^2}$$

- MAPE（平均相对误差）:它是真值与预测值之差再除以真值之后取平均值，反 映相对误差。

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\frac{\left|y_i^{real} - y_i^{pred}\right|}{y_i^{real}}$$

后期计划

北京交通大学 BEIJING JIAOTONG UNIVERSITY

2025.12-2026.3

完成所有核心模块的代码实现，并完成端到端模型的集成与初步调试。

2026.4-2026.8

通过系统的实验设计，定量与定性地验证模型的有效性与创新性。完整训练+消融实验
参数敏感性分析+对比实验

2026.9-2026.12

深入分析实验结果，完成毕业论文的初稿撰写与修改。结果可视化与案例分析，毕业论文初稿撰写。

2027.1-2027.5

毕业论文
毕业答辩

参考文献

[1] Gu, A., & Dao, T. (2023). Mamba: Linear-Time Sequence Modeling with Selective State Spaces. arXiv preprint arXiv:2312.00752.

[2] Liu, Y., Wu, C., Wang, J., & Xu, T. (2023). Spatial-Temporal Identity: A Simple yet Effective Baseline for Multivariate Time Series Forecasting. arXiv preprint arXiv:2302.11483.

[3] Liu, M., et al. (2022). SCINet: Time Series Modeling and Forecasting with Sample Convolution and Interaction. Advances in Neural Information Processing Systems, 35.

[4] Wu, Z., et al. (2021). Graph WaveNet: Deep Spatial-Temporal Graph Modeling for Urban Traffic Forecasting. IEEE Transactions on Knowledge and Data Engineering.

[5] Zhu, L., et al. (2024). Graph Machine Learning for Time Series: A Survey. arXiv preprint arXiv:2403.00729.

[6] Zhang, X., et al. (2024). Mamba-Former: Hybrid State Space Model and Transformer for Long-Sequence Time Series Forecasting. arXiv preprint arXiv:2402.14592.

[7] Wang, Y., et al. (2024). Dynamic Graph Convolutional Networks with Adaptive Node Embedding for Traffic Flow Prediction. IEEE Transactions on Intelligent Transportation Systems.

[8] Chen, S., et al. (2023). CrossFormer: A Versatile Vision Transformer Based on Cross-scale Attention. International Conference on Machine Learning (ICML).

北京交通大學
BEIJING JIAOTONG UNIVERSITY

敬请各位老师批评指正

汇报人： 倪矗

指导老师： 黄惠芳