要实现准确的预测，我们必须深入理解交通数据的本质特性。交通流数据具有非常典型的**时空双重依赖性**

首先，是**时间相关性**。交通流量并不是随机波动的，它受到多种时间尺度因素的影响。比如，我们每天经历的早高峰和晚高峰，工作日与周末节假日的流量差异，甚至是一些突发的交通事故或天气变化，都会在时间维度上留下特定的模式。其次，是**空间相关性**。城市路网中的各个节点，比如交通传感器或收费站，并不是孤立存在的，它们通过道路连接成一个复杂的**图结构**。

时间序列数据在进行下采样后，仍然能够保留重要的时间关系，这一点与许多其他类型的序列数据不同。

多尺度时间依赖：时空数据在不同尺度下，存在着不同的时空相关性，交通流量预测建模需要考虑多尺度下的时间和空间特征。

正如这张图所示，交通数据在不同时间粒度下会呈现出截然不同的趋势。短期来看可能有瞬时波动，长期来看则存在明显的早晚高峰周期。

第二，是**空间异质性**。城市中不同区域的功能是不同的，比如商业区、住宅区、工业区，它们的交通模式存在显著差异。如果我们忽略这种差异，用一个统一的模型去处理所有节点，必然会严重影响预测的精度。

正是这些复杂的特性，使得时空交通流预测成为一个极具挑战性的研究课题。

7. 我们可以从一下两个方面来进行建模，
8. **在时间建模方面**，主流模型主要有三类：
9. 它的自注意力机制非常强大，能够直接建模序列中任意两个时间点之间的关系，完美解决了长期依赖问题。然而，其计算复杂度随着序列长度的增加呈**平方级增长**，这导致它难以处理交通领域常见的超长序列数据。

10.,类模型通过递归地将序列下采样为奇偶子序列并进行交互，从而实现多尺度时间建模，来增强特征表达。但它仍然没有充分利用下采样后多分辨率序列所保留的全局信息。

11.大多数方法将路网建模为图结构。**早期模型如STGCN和DCRNN**，

12.**后续模型如Graph WaveNet**引入了**自适应邻接矩阵**，这是一个可学习的矩阵，在一定程度上缓解了对预定义图的依赖。**近期工作如STIDGCN**，

13. 综上所述，当前研究面临的核心问题可以归纳为三点：
14. 具体来说，我们让奇数和偶数两个子序列之间进行双向的信息交互。每一方都可以作为查询，去主动关注另一方中对自己有用的信息。这是一个动态的、内容感知的过程，能够极大地补偿下采样过程中可能造成的信息损失，从而增强模型对多尺度时间依赖的理解。

20. 这个门控会学习为一个权重，来决定在最终的空间表示中，静态模式和动态模式各占多少比重。这种结构化的融合方式，能够有效避免信息冲突，让模型更稳定、更高效地学习空间特征。

如何在时间序列下采样后充分利用保留的趋势性、周期性等全局信息，实现多尺度的深层时间依赖建模？

交通流的时间模式是**动态变化**的。早高峰的规律性与平峰期、突发拥堵时的模式完全不同。一个固定的感受野无法自适应地捕捉这些**随上下文变化的时间尺度**。可能感受野设小了抓不到周依赖，设大了又会引入过多噪声，且计算负担加重。

捕捉“周一早高峰”与“周五晚高峰”之间的远程关联；识别节假日事件对前后数天交通模式的持续影响。

无法做到 对于重要的信息加强交互，对于噪声或无关信息减弱交互。

可以**自主决定**在交互时应该关注什么，忽略什么。