

南京邮电大学学报(自然科学版)
Journal of Nanjing University of Posts and Telecommunications(Natural Science Edition)
ISSN 1673-5439,CN 32-1772/TN

《南京邮电大学学报(自然科学版)》网络首发论文

题目：基于压缩空间注意力和序列聚合重分配的交通流量预测
作者：杨真真，何袁梁，徐奕
收稿日期：2025-08-22
网络首发日期：2025-11-12
引用格式：杨真真，何袁梁，徐奕．基于压缩空间注意力和序列聚合重分配的交通流量预测[J/OL]．南京邮电大学学报(自然科学版).
https://link.cnki.net/urlid/32.1772.TN.20251112.1024.003



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-11-12 11:53:54　网络首发地址：https://link.cnki.net/urlid/32.1772.TN.20251112.1024.003

基于压缩空间注意力和序列聚合重分配的交通流量预测

杨真真,何袁梁,徐奕

(南京邮电大学 理学院，江苏 南京 210003)

摘要：针对现有交通流量预测方法难以同时兼顾全局路网趋势与局部路段细节，且对交通数据长期依赖关系建模不足的问题，提出了一种基于压缩空间注意力和序列聚合重分配(Compressed Spatial Attention and Sequence Aggregation Redistribution, CSA-SAR)的交通流量预测方法。首先，设计了压缩空间注意力机制，通过轴向压缩技术减少冗余信息干扰，并通过卷积模块增强交通数据关键空间特征的细节表达。其次，设计了序列聚合重分配模块，利用随机池化生成全局状态的核心表示，并通过动态拼接与局部时间特征结合，以改善长期依赖关系建模中全局与局部信息的融合效果。然后，设计了多尺度时间信息提取模块，通过多尺度卷积捕捉交通数据不同时间尺度特征，与序列聚合模块协同优化时间维度建模。最后，在三个数据集上的仿真实验表明，提出的 CSA-SAR 均优于现有交通流量预测方法。

关键词：交通流量预测；压缩空间注意力；序列聚合重分配；多尺度时间信息；多尺度卷积

中图分类号：TP391　　**文献标识码：**A

Compressed Spatial Attention and Sequence Aggregation Redistribution for Traffic Flow Forecasting

YANG Zhenzhen，HE Yuanliang，XU Yi

(College of Science, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

Abstract: To address the limitations of existing traffic flow forecasting methods in capturing both global road network trends and local segment details, as well as insufficient modeling of long-term dependencies of traffic data, this paper proposes the compressed spatial attention and sequence aggregation redistribution (CSA-SAR) for traffic flow forecasting. Firstly, the compressed spatial attention mechanism reduces redundant information via axial compression and enhances key spatial features of traffic data with convolutional modules, improving the representation of critical details. Moreover, the sequence aggregation redistribution module uses stochastic pooling to generate core global representations, dynamically fusing them with local temporal features to improve the integration of global and local information. Additionally, a multi-scale temporal feature extraction module captures features at different time scales of traffic data through multi-scale convolutions, further optimizing temporal modeling and enhancing adaptability to complex patterns. Extensive experiments on 3 datasets demonstrate that the proposed CSA-SAR consistently outperforms existing traffic flow forecasting methods.

Keywords: traffic flow forecasting; compressed spatial attention; sequence aggregation redistribution; multi-scale temporal information; multi-scale convolution

收稿日期：2025-08-22;**修回日期:**2025-10-26　**本刊网址:**http://nyzr.njupt.edu.cn

基金项目：国家自然科学基金(62571269)和江苏省研究生科研与实践创新计划项目(KYCX_241125, SJCX_240279)资助项目

作者简介：杨真真，女，博士，副教授，yangzz@njupt.edu.cn

交通流量预测作为智能交通系统(Intelligent Traffic System, ITS)[1]的核心技术之一，对改善交通管理、缓解交通拥堵以及提升公共交通调度效率具有重要意义。该预测不仅涉及到海量历史交通数据，还需深入分析其复杂的时空动态性、异质性和依赖性，成为智能交通领域极具挑战性的任务之一。

早期的交通流量预测研究主要基于传统统计学，如 Ben 等[2]提出的自回归移动平均(Auto-Regressive Integrated Moving Average, ARIMA)模型因其简单高效被广泛应用。Stock 等[3]提出的向量自回归(Vector Auto Regressive, VAR)进一步扩展了多变量时间序列建模能力[4]，但这类方法都基于线性假设，难以有效捕捉交通数据的复杂非线性关系[5]。后来，机器学习方法也被用来交通预测。Drucker 等[6]提出的支持向量回归(Support Vector Regression, SVR)通过核函数技巧引入非线性建模能力，在一定程度上提升了预测性能。然而，这类方法仍难以有效捕捉交通数据的复杂高维时空依赖性，尤其在大规模交通网络下对其空间特征的建模能力有限。

随着深度学习技术的不断发展，许多研究被用于交通预测。例如，Li 等[7]提出了扩散卷积循环神经网络(Diffusion Convolutional Recurrent Neural Network, DCRNN)，将图卷积网络(Graph Convolutional Network, GCN)[8]与循环神经网络(Recurrent Neural Network, RNN)[9]结合，有效捕获交通数据的时空依赖性，提升了预测精度。Song 等[10]提出了时空同步图卷积网络(Spatial-Temporal Synchronous Graph Convolutional Network, STSGCN)，通过时空同步建模有效捕捉交通数据局部复杂时空依赖性和动态性。Wu 等[11]提出了图小波网络(Graph WaveNet, GWNet)，结合自适应 GCN 和扩展因果卷积，同时处理交通数据的空间和时间依赖性。Zheng 等[12]提出了图多头注意力网络(Graph Multi-Attention Network, GMAN)，通过引入多头注意力机制捕捉图中节点间的时空依赖关系。虽然该类方法提升了对交通数据时空依赖性的建模能力，但在融合全局与局部信息、处理长期依赖以及复杂时间波动方面仍存在不足。

此外，很多研究提出了更先进的深度学习方法以优化时空依赖建模能力。例如，Li 等[13]提出了时空融合图神经网络(Spatial-Temporal Fusion Graph Neural Network, STFGNN)，同时捕捉交通数据的局部和全局时空依赖性。Kong 等[14]提出了时空关键图神经网络(Spatio-Temporal Pivotal Graph Neural Network, STPGNN)，通过引入枢纽节点识别和 GCN 模块，解决了复杂时空依赖建模问题。Wu 等[15]提出了多异构图神经网络(Multi-Heterogeneous Graph Neural Network, MHGNet)，通过多异构图神经网络架构处理复杂时空数据。尽管这些图神经网络(Graph Neural Network, GNN)方法[16-17]在捕获复杂时空依赖性等方面表现出色，但在多尺度时间特征提取方面存在局限，难以同时兼顾不同时间尺度下的交通流量变化[18]。Transformer[19]因其在捕捉长程依赖性的突出能力，被广泛用于交通流量预测[20-21]。Yan 等[22]采用 Transformer 学习动态和层次化的交通时空特征，提出了交通 Transformer (Traffic Transformer, TFormer)用于捕捉交通数据中的复杂时空关系。Jiang 等[23]提出了传播延迟 Transformer (Propagation Delay-aware Dynamic Long-range Transformer, PDFormer)，引入传播延迟机制提升预测精度。这类方法在长时依赖和全局特征建模方面表现突出，但在空间信息冗余抑制、全局与局部信息融合以及多尺度时间特征提取方面仍存在缺陷。

针对上述问题，提出了一种基于压缩空间注意力和序列聚合重分配(Compressed Spatial Attention and Sequence Aggregation Redistribution, CSA-SAR)的交通流量预测方法。该方法结合了压缩空间注意力、序列聚合重分配以及多尺度时间信息提取模块，旨在更有效地建模交通数据中的复杂时空关系。压缩空间注意力机制利用轴向注意力，通过对空间信息进行压缩有效减少冗余信息的干扰，同时对重要的空间特征进行细节增强，提升其空间依赖建模能力，能更好地捕捉到关键空间依赖关系。序列聚合重分配模块在时间维度上对交通数据长期依赖关系进行优化，利用随机池化生成全局状态的核心表示，同时将核心表示与各通道的局部时间特征动态融合，既保留路网节点传感器特异性又整合路网全局信息，能够捕捉交通数据的长时依赖和复杂时间波动。多尺度时间信息提取模块通过并行使用不同大小的卷积核处理时序信息，在不同时间尺度下提取交通流量的时间特征。此外，在三个真实交通数据集上进行的仿真实验表明，提出的 CSA-SAR 优于现有交通预测方法。

1 基于 CSA-SAR 的交通流量预测

1.1 问题定义与描述

路网表示为$\mathcal{G}=(\mathcal{V},\mathcal{E},\boldsymbol{A})$，其中$\mathcal{V}$是节点集合，$\mathcal{E}$是连接节点边集合，$\boldsymbol{A}$是路网邻接矩阵。通过可学习的映射函数，采用前$P$步的交通流量和路网拓扑结构来预测未来$Q$步的交通流量，表示为：

$$[\boldsymbol{X}_1,\boldsymbol{X}_2,\cdots,\boldsymbol{X}_P;\mathcal{G}]\xrightarrow{f}[\boldsymbol{X}_{P+1},\boldsymbol{X}_{P+2},\cdots,\boldsymbol{X}_{P+Q}]$$

1.2 整体框架

基于 CSA-SAR 的交通流量预测整体框架如图 1 所示。该框架首先构建了数据嵌入层，接收多维交通流量数据。然后设计了包括空间处理层和时间处理层的时空编码层，其中空间处理层包含压缩空间注意力和空间依赖注意力，时间处理层包含序列聚合重分配机制和多尺度时间信息提取模块。最后，空间处理层和时间处理层的结果经过拼接，以全面整合时空信息并输出最终预测结果。

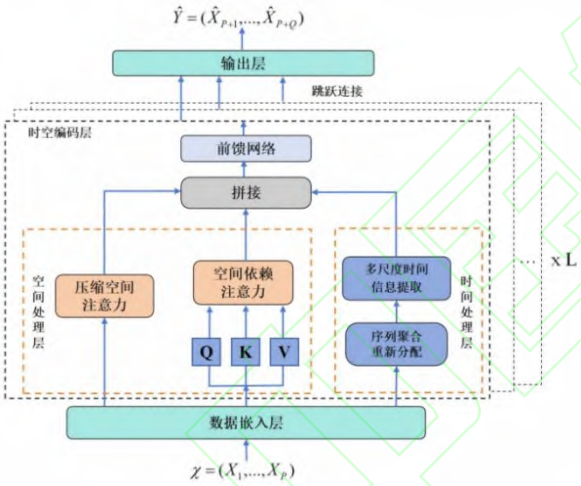


图 1 CSA-SAR 整体框架

1.3 数据嵌入层

数据嵌入层接收多维交通数据，经过全连接网络初步处理。该层利用图拉普拉斯特征刻画道路拓扑结构和节点空间关系，并融入周、日周期特征和时间位置编码，全面反映交通流量的周期性变化和时序信息。最后，有效融合原始数据、空间结构特征和时间特性，为后续时空建模提供高维有效输入。

1.4 时空编码层

时空编码层是 CSA-SAR 的核心部分，旨在高效提取交通流量数据中的复杂时空关系。该层由空间处理层和时间处理层构成，共同实现时空特征建模。其中，空间处理层包括压缩空间注意力和空间依赖注意力机制，时间处理层包括序列聚合重分配和多尺度时间信息提取模块，以充分挖掘交通流量数据中的时空依赖性和动态性。

1.4.1 压缩空间注意力模块

交通流量数据具有复杂的空间依赖性，以及路网节点之间的关系存在动态变化和冗余信息，传统预测方法往往难以高效捕捉其关键空间特征。受到压缩轴向注意力机制[24]的启发，提出了压缩空间注意力机制，旨在利用压缩轴向操作减少空间信息冗余，并通过细节增强机制强化关键特征表达。其结构如图 2 所示。

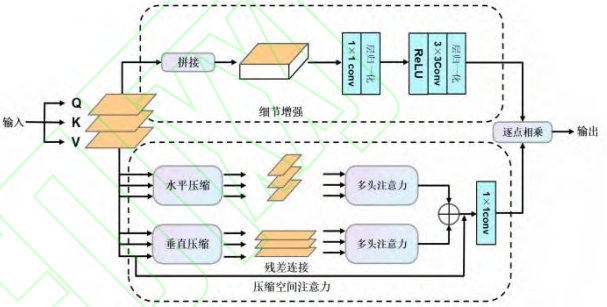


图 2 压缩空间注意力模块

首先，将进入压缩空间注意力模块的数据 $\boldsymbol{X}_s$，通过三个线性变换生成查询矩阵 $\boldsymbol{Q}$、键矩阵 $\boldsymbol{K}$ 和值矩阵 $\boldsymbol{V}$，计算过程如下:

$$\boldsymbol{Q}=\boldsymbol{W}_q\boldsymbol{X}_s,\boldsymbol{K}=\boldsymbol{W}_k\boldsymbol{X}_s,\boldsymbol{V}=\boldsymbol{W}_v\boldsymbol{X}_s \quad (1)$$

其中$\boldsymbol{W}_q,\boldsymbol{W}_k,\boldsymbol{W}_v$均为可学习参数。

接着，在水平方向上提取$\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}$特征图的平均值并进行水平压缩，计算过程如下：

$$\boldsymbol{Q}_{(h)}=\frac{1}{\mathrm{W}}(\boldsymbol{Q}\,\boldsymbol{I}_{\mathrm{W}}),\ \boldsymbol{K}_{(h)}=\frac{1}{\mathrm{W}}(\boldsymbol{K}\,\boldsymbol{I}_{\mathrm{W}}),\ \boldsymbol{V}_{(h)}=\frac{1}{\mathrm{W}}(\boldsymbol{V}\,\boldsymbol{I}_{\mathrm{W}}) \quad (2)$$

其中，$\boldsymbol{I}_{\mathrm{W}}\in\mathrm{R}^{W\times 1}$是长度为 W 的全 1 向量。矩阵乘法结果对 W 方向上的所有特征进行平均化处理，以有效减少空间信息的冗余，同时保留关键信息。在垂直方向通过类似方法对$\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}$进行压缩，过程如下：

$$\boldsymbol{Q}_{(v)}=\frac{1}{\mathrm{H}}(\boldsymbol{Q}\,\boldsymbol{I}_{\mathrm{H}}),\ \boldsymbol{K}_{(v)}=\frac{1}{\mathrm{H}}(\boldsymbol{K}\,\boldsymbol{I}_{\mathrm{H}}),\ \boldsymbol{V}_{(v)}=\frac{1}{\mathrm{H}}(\boldsymbol{V}\,\boldsymbol{I}_{\mathrm{H}}) \quad (3)$$

其中，$\boldsymbol{I}_{\mathrm{H}}\in\boldsymbol{R}^{W\times 1}$是长度为 H 的全 1 向量。通过压缩操作，全局信息被保留到单个轴上，并分别采用自注意力机制建模交通数据的长期依赖性，最后通

过广播操作将二者相加得到：

$$\begin{aligned}\boldsymbol{Y}_{(h)} &= \text{softmax}(\frac{\boldsymbol{Q}_{(h)}\boldsymbol{K}_{(h)}^{T}}{\sqrt{d_k}})\boldsymbol{V}_{(h)} \\ \boldsymbol{Y}_{(v)} &= \text{softmax}(\frac{\boldsymbol{Q}_{(v)}\boldsymbol{K}_{(v)}^{T}}{\sqrt{d_k}})\boldsymbol{V}_{(v)} \\ \boldsymbol{Y}' &= \text{broadcast}\,(\boldsymbol{Y}_{(h)}) + \text{broadcast}\,(\boldsymbol{Y}_{(v)})\end{aligned} \tag{4}$$

其中，$\text{softmax}(\cdot)$ 为 softmax 激活函数，$\text{broadcast}(\cdot)$ 为广播操作，d_k 为特征位数。最后，采用残差连接将输入特征与压缩轴向输出结果直接相加，并采用 1×1 卷积得到压缩空间注意力的输出，提升特征在网络中的流动效率和融合能力，并增强模型稳定性和泛化能力。过程如下：

$$\boldsymbol{Y} = \text{Conv}_{1\times1}(\boldsymbol{Y}' + \boldsymbol{V}) \tag{5}$$

其中，$\text{Conv}_{1\times1}(\cdot)$ 为 1×1 卷积操作。

此外，为进一步提升空间特征的表达能力，采用细节增强机制。首先，将输入数据 $\boldsymbol{X}_s$ 引入额外的可学习参数 $\boldsymbol{W}_q^{(e)}, \boldsymbol{W}_k^{(e)}, \boldsymbol{W}_v^{(e)}$ 进行细节增强处理，计算过程如下：

$$\boldsymbol{Q}_{(e)} = \boldsymbol{W}_q^{(e)}\boldsymbol{X}_s,\ \boldsymbol{K}_{(e)} = \boldsymbol{W}_k^{(e)}\boldsymbol{X}_s,\ \boldsymbol{V}_{(e)} = \boldsymbol{W}_v^{(e)}\boldsymbol{X}_s \tag{6}$$

随后，将生成的 $\boldsymbol{Q}_{(e)}$，$\boldsymbol{K}_{(e)}$，$\boldsymbol{V}_{(e)}$ 在通道维度拼接，并馈入到 1×1 卷积和批归一化层，以建模交通数据的局部空间依赖，从而增强其局部细节感知，得到：

$$\boldsymbol{X}_{qkv} = \text{BN}(\text{Conv}_{1\times1}(\text{Concat}(\boldsymbol{Q}_{(e)}, \boldsymbol{K}_{(e)}, \boldsymbol{V}_{(e)}))) \tag{7}$$

其中，$\text{BN}(\cdot)$ 为批归一化操作，$\text{Concat}(\cdot)$ 为拼接操作。接着，对 $\boldsymbol{X}_{qkv}$ 应用 ReLU 激活函数，并通过一个带有批归一化层的 3×3 卷积操作，生成细节增强特征：

$$\boldsymbol{X}'_{qkv} = \text{BN}(\text{Conv}_{3\times3}(\text{ReLU}(\boldsymbol{X}_{qkv}))) \tag{8}$$

其中，$\text{Conv}_{3\times3}(\cdot)$ 为 3×3 卷积操作，$\text{ReLU}(\cdot)$ 为修正线性单元操作。

最后，通过对压缩空间注意力输出 $\boldsymbol{Y}$ 进行 sigmoid 激活，生成自适应权重，与增强特征逐点相乘，实现对不同空间位置特征的动态分配，得到压缩空间注意力模块的输出为：

$$\boldsymbol{Z}_{csa} = \text{sigmoid}(\boldsymbol{Y}) \odot \boldsymbol{X}'_{qkv} \tag{9}$$

其中，$\text{sigmoid}(\cdot)$ 为 sigmoid 激活函数。

1.4.2 空间依赖注意力模块

首先，将进入空间依赖注意力模块的数据 $\boldsymbol{X}_d$ 通过三个线性变换生成查询矩阵、键矩阵和值矩阵，计算过程如下:

$$\boldsymbol{Q}_d = \boldsymbol{W}'_q\boldsymbol{X}_d, \boldsymbol{K}_d = \boldsymbol{W}'_k\boldsymbol{X}_d, \boldsymbol{V}_d = \boldsymbol{W}'_v\boldsymbol{X}_d \tag{10}$$

其中 $\boldsymbol{W}'_q, \boldsymbol{W}'_k, \boldsymbol{W}'_v$ 均为可学习参数。

在空间维度上采用自注意力机制来模拟节点间的交互，以更好地适应交通流量的动态变化。通过计算查询和键矩阵的内积获得注意力矩阵，并采用 softmax 函数对其进行归一化，以得到每个节点的加权值：

$$\textit{Attention}(\boldsymbol{Q}_d, \boldsymbol{K}_d, \boldsymbol{V}_d) = \text{softmax}(\frac{\boldsymbol{Q}_d\boldsymbol{K}_d^{T}}{\sqrt{d'}})\boldsymbol{V}_d \tag{11}$$

其中 d' 是查询、键和值矩阵的维度。值得注意的是，在实际应用中，对于空间自注意力机制，并非所有节点之间的交互都是必要的。

为提高计算效率并忽略相对较远的节点的影响，采用图掩码矩阵 $\boldsymbol{M}_d$ 来捕捉节点间的空间依赖关系。$\boldsymbol{M}_d$ 仅在相邻节点间起作用，当两节点距离小于阈值 λ 时权重为 1，否则为 0。$\boldsymbol{M}_d$ 公式如下：

$$\boldsymbol{M}_d(i,j) = \begin{cases} 1 & \text{if } d_{ij} < \lambda \\ 0 & \text{if } d_{ij} > \lambda \end{cases} \tag{12}$$

其中，$\boldsymbol{M}_d(i,j)$ 表示掩码矩阵中第 i 行第 j 列元素，d_{ij} 表示节点 i 和节点 j 之间的欧式距离，λ 是预设的阈值。通过引入图掩码矩阵 $\boldsymbol{M}_d$，设计了空间自注意力，其格式如下：

$$\boldsymbol{A}_d(\boldsymbol{Q}_d,\boldsymbol{K}_d,\boldsymbol{V}_d)=\text{softmax}(\frac{\boldsymbol{Q}_d\boldsymbol{K}_d^T\odot\boldsymbol{M}_d}{\sqrt{d'}})\boldsymbol{V}_d \quad (13)$$

其中，$\odot$表示哈达玛积。

最后，得到空间依赖模块的最终输出为：

$$\boldsymbol{Z}_d=\boldsymbol{A}_d(\boldsymbol{Q}_d,\boldsymbol{K}_d,\boldsymbol{V}_d) \quad (14)$$

1.4.3 序列聚合重分配模块

交通流量的动态变化不仅取决于单一路段的历史观测数据，还受到整个路网中其他节点协同变化的影响。受文献[25]的启发，提出序列聚合重分配机制，动态提取每个时刻全局核心特征，并将其与各节点的局部特征深度融合。其结构如图 3 所示。

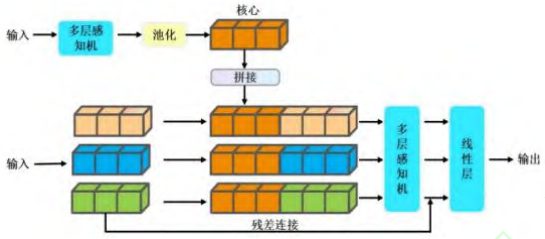


图 3　序列聚合重新分配模块

首先，对序列聚合重分配模块的输入数据 $\boldsymbol{X}_t$ 中 C 个时间步 $s_1,s_2,\ldots,s_C$ 进行处理得到核心表示：

$$\boldsymbol{o}=\text{SP}(\text{GELU}(\text{MLP}(s_1,s_2,\ldots,s_C))) \quad (15)$$

其中，$\text{MLP}(\cdot)$ 表示多层感知机操作，$\text{GELU}(\cdot)$ 为 GELU 激活函数，$\text{SP}(\cdot)$ 表示随机池化操作。核心表示 $\boldsymbol{o}$ 对所有通道上的全局信息进行编码[26-27]。

在特征融合阶段，实现全局核心信息与局部原始特征的深度融合。将聚合的全局核心表示 $\boldsymbol{o}$ 复制 C 次得到 $\boldsymbol{O}$。并将其与原始输入 $\boldsymbol{X}_t$ 进行拼接，拼接后的特征经多层感知机进行非线性映射和融合，增强了特征表达能力，使其能有效捕捉到全局与局部信息间更为复杂的非线性交互关系。其过程如下：

$$\boldsymbol{X}_t'=\text{MLP}(\text{Concat}(\boldsymbol{O},\boldsymbol{X}_t)) \quad (16)$$

输出 $\boldsymbol{X}_t'$ 不仅包含全局时间信息，还保留了该时刻的局部特征。

1.4.4 多尺度时间信息提取模块

受文献[28]的启发，针对交通流量预测的时间特征，设计多尺度时间信息提取模块，采用多种卷积核并行提取不同时间尺度特征，旨在进一步聚焦时间维度的多尺度特性。其结构如图 4 所示。

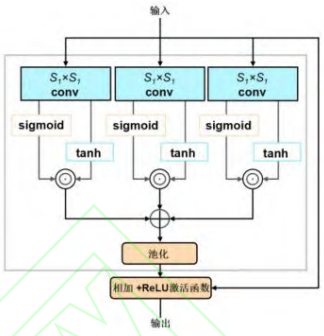


图 4　多尺度时间信息提取模块

首先，对经过序列聚合重分配模块处理后的输入数据 $\boldsymbol{X}_t'$ 进行并行多尺度卷积操作，以全面提取不同时间尺度特征。通过设置不同大小的卷积核，对时间维度的输入数据进行卷积操作，分别得到特征图 $\boldsymbol{X}_{t_1},\boldsymbol{X}_{t_2},\boldsymbol{X}_{t_3}$：

$$\begin{aligned}\boldsymbol{X}_{t_1}&=\text{Conv}_{s_1\times s_1}(\boldsymbol{X}_t')\\ \boldsymbol{X}_{t_2}&=\text{Conv}_{s_2\times s_2}(\boldsymbol{X}_t')\\ \boldsymbol{X}_{t_3}&=\text{Conv}_{s_3\times s_3}(\boldsymbol{X}_t')\end{aligned} \quad (17)$$

其中，$\text{Conv}_{s_1\times s_1},\text{Conv}_{s_2\times s_2},\text{Conv}_{s_3\times s_3}$ 分别表示 $s_1\times s_1$，$s_2\times s_2$，$s_2\times s_2$ 的卷积操作。

其次，针对每个尺度卷积获得的特征图 $\boldsymbol{X}_{t_1},\boldsymbol{X}_{t_2},\boldsymbol{X}_{t_3}$，分别独立沿通道方向将其平均分成 $\boldsymbol{E}$ 和 $\boldsymbol{F}$ 两部分。同时，结合 Tanh 和 sigmoid 激活函数分别处理 $\boldsymbol{E}$ 和 $\boldsymbol{F}$，并构建门控单元，实现更细致的信息控制。通过逐点相乘控制和融合每个尺度下的时间依赖特征表示。具体计算过程如下：

$$\begin{aligned}\boldsymbol{E},\boldsymbol{F}&=\text{Split}(\boldsymbol{X}_{t_m})\\ \boldsymbol{Y}_m&=\tanh(\boldsymbol{E})\odot\text{sigmoid}(\boldsymbol{F})\end{aligned} \quad (18)$$

其中，$\text{Split}(\cdot)$ 表示分裂操作，tanh 和 sigmoid 均为激活函数，$m=1,2,3$。

此外，为有效整合不同尺度的特征信息，对每个尺度的输出$\boldsymbol{Y}_1,\boldsymbol{Y}_2,\boldsymbol{Y}_3$进行池化操作，以聚合其关键信息并降低维度。同时，将池化后的多尺度特征进行拼接，形成包含多尺度时序信息的表示$\boldsymbol{Y}'$：

$$\boldsymbol{Y}'=\mathrm{Concat}(\mathrm{Pooling}(\boldsymbol{Y}_1,\boldsymbol{Y}_2,\boldsymbol{Y}_3)) \tag{19}$$

其中，$\mathrm{Pooling}(\cdot)$表示池化操作。

最后，为增强模型的稳定性和特征流动效率，引入残差连接和 ReLU 激活函数。将多尺度处理后的融合特征$\boldsymbol{Y}'$与输入$\boldsymbol{X}_t'$相加，再通过 ReLU 激活函数，得到时间处理层的最终输出$\boldsymbol{Z}_t$：

$$\boldsymbol{Z}_t=\mathrm{ReLu}(\boldsymbol{Y}'+\boldsymbol{X}_t') \tag{20}$$

1.5 时空融合注意力

为了整合来自不同注意力机制的信息，每个注意力模块的输出进行拼接和投影，其格式为：

$$\mathrm{STA}=\mathrm{Concat}(\boldsymbol{Z}_{csa},\boldsymbol{Z}_d,\boldsymbol{Z}_t)\boldsymbol{W}^o \tag{21}$$

其中，$\boldsymbol{W}^o$是一个可学习的投影矩阵。此外，对融合注意力模块的输出使用前馈网络、残差连接和层归一化，获得输出$\boldsymbol{X}_o$。具体过程如下：

$$\boldsymbol{X}_o=\mathrm{LN}(\mathrm{STA}+\mathrm{FFN}(\mathrm{STA})) \tag{22}$$

其中，$\mathrm{LN}(\cdot)$为层归一化，$\mathrm{FFN}(\cdot)$为前馈网络。

1.6 输出层

在每个时空编码层之后使用跳跃卷积操作，并对每个跳跃连接层的输出进行求和，获得最终的隐藏状态$\boldsymbol{X}_{hid}$。具体过程如下：

$$\boldsymbol{X}_{hid}=\sum_{l=1}^{L}\mathrm{skipConv}(\boldsymbol{X}_o^l) \tag{23}$$

其中，$\mathrm{skipConv}(\cdot)$为跳跃卷积操作，$\boldsymbol{X}_o^l$表示第l层时空编码层的输出。

为了进行多步预测，采用两层 1×1 卷积对隐藏状态$\boldsymbol{X}_{hid}$进行处理，得到如下Q步的预测结果：

$$\hat{\boldsymbol{X}}=\mathrm{Conv}_{1\times1}(\mathrm{Conv}_{1\times1}(\boldsymbol{X}_{hid})) \tag{24}$$

2 实验与结果分析

2.1 数据集

在 3 个真实交通流量数据集 PeMS04、PeMS07 和 PeMS08 上进行了仿真实验，以验证和评估提出的 CSA-SAR 的性能。三个数据集分别包含了 307、883 和 170 个路网节点的交通流量数据。原始交通流量数据每 30 秒采集一次，统计时间间隔均为 5 分钟，即每个传感器每小时统计 12 次。

2.2 基线模型与评价指标

基线模型包括：VAR 和 SVR 分别属于传统统计学与机器学习方法；DCRNN 属于传统深度学习方法；STGCN、STSGCN、GWNet、GMAN、STFGNN、STPGNN 和 MHGNET 是基于 GNN 的时空深度学习模型；TFormer 和 PDFormer 是基于 Transformer 架构的方法。

为了定量评价不同方法的预测性能，选取了平均绝对误差(Mean Absolute Error, MAE)、均方根误差(Root Mean Squared Error，RMSE)和平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)三种评估指标。

2.3 实验设置

实验使用 PyTorch 库实现，并在 NVIDIA 3090 GPU 上进行训练。将三个数据集按 6:2:2 的比例分为训练集、验证集和测试集。使用过去 1 小时(12 个时间步)的交通数据来预测未来 1 小时的交通流量。实验中 PeMS04、PeMS07 和 PeMS08 对应的隐藏维度分别是 64，32，128，编码器层数分别是 4，6，2。使用 AdamW 优化器进行训练，学习率为 0.001，批量大小为 16，训练的 epoch 为 200。所有实验均为重复 3 次并取平均值作为结果。

2.4 性能对比实验

为了验证提出的 CSA-SAR 的预测性能，在 3 个真实的交通流量数据集上进行了性能对比实验，实验结果如表 1 所示。

表 1 展示了提出的 CSA-SAR 与基线方法在未来 1 小时的平均预测结果。其中“_”表示次优性能，粗体代表最佳性能。CSA-SAR 在 3 个流量数据集上的性能几乎均优于现有交通流量预测方法。在 PEMS04 数据集的 MAE、MAPE 相比于 STPGNN 分别下降了 0.33%、3.01%，在 PEMS07 数据集的

MAE、MAPE、RMSE 相比于 MHGNET 分别下降了 0.27%、1.77%、0.07%，在 PEMS08 数据集的 MAE、MAPE、RMSE 相比于 PDFormer 分别下降了 0.28%、0.25%、0.95%。表 1 结果显示，提出的 CSA-SAR 综合考虑交通流量的短期波动和长期趋势，通过引入压缩空间注意力机制，提升空间依赖建模能力。此外，序列聚合重分配模块提升了对交通数据长期依赖性和时间波动的建模能力。最后，采用多尺度时间信息提取模块进行多尺度建模，在不同时间尺度下有效提取交通流量的时间特征。提出的 CSA-SAR 展现出了优异的预测性能，特别是在复杂的交通场景中，显著优于现有交通预测方法。

表 1　各方法在三个数据集上的性能比较

Model	PeMS04			PeMS07			PeMS08		
	MAE	MAPE(%)	RMSE	MAE	MAPE(%)	RMSE	MAE	MAPE(%)	RMSE
VAR	23.750	18.090	36.660	101.200	39.690	155.140	22.320	14.470	33.830
SVR	28.660	19.150	44.590	32.970	15.430	50.150	23.250	14.710	36.150
DCRNN	22.737	14.751	36.575	23.634	12.281	36.514	18.185	11.235	28.176
STGCN	21.758	13.874	34.769	22.898	11.983	35.440	17.838	11.211	27.122
GWNet	19.358	13.301	31.719	21.221	9.075	34.117	15.063	9.514	24.855
STSGCN	21.185	13.882	33.649	24.264	10.204	39.034	17.133	10.961	26.785
STFGNN	19.830	13.021	31.870	22.072	9.212	35.805	16.636	10.547	26.206
STGNCDE	19.211	12.772	31.088	20.620	8.864	34.036	15.455	9.921	24.813
GMAN	19.139	13.192	31.601	20.967	9.052	34.097	15.307	10.134	24.915
TFormer	18.916	12.711	31.349	20.754	8.972	34.062	15.192	9.925	24.883
PDFormer	18.418	12.214	30.091	19.759	8.417	32.801	13.624	9.034	23.568
STPGNN	18.341	12.492	**29.640**	20.253	8.751	33.384	13.902	9.013	23.351
MHGNET	18.320	12.301	29.961	19.521	8.456	32.664	13.962	9.031	**23.223**
CSA-SAR	**18.280**	**12.126**	29.843	**19.467**	**8.306**	**32.642**	**13.585**	**9.011**	23.344

2.5　消融分析

为了验证提出模块的有效性，分别从以下变体对 PEMS08 数据集进行消融实验，结果如表 2 所示。

表 2　消融实验结果

模型	MAE	MAPE(%)	RMSE
w/o C	13.681	9.155	23.937
w/o S	13.643	9.121	23.865
w/o M	13.675	9.143	23.826
w/o D	13.628	9.112	23.834
w/o C-D	13.712	9.211	23.963
w/o S-M	13.702	9.225	23.954
CSA-SAR	13.585	9.011	23.344

由表 2 可以看出，提出的 CSA-SAR 相较于其他变体具有更优的预测性能，充分验证了其各个模块的有效性。具体而言，去除压缩空间注意力模块(w/o C)，序列聚合重分配模块(w/o S)，多尺度信息提取模块(w/o M)，空间依赖注意力模块(w/o D)的性能均下降，表明这些模块在联合处理交通流量数据时具有重要的协同作用。去除空间模块(w/o C-D)和去除时间时间模块(w/o S-M)，平均预测性能也都降低，表明空间模块和时间模块在捕捉交通流量数据的时空间依赖性和动态性等方面的重要性。

2.6　复杂度对比实验

提出的 CSA-SAR 与先进预测方法 MHGNet 和 PDFormer 在不同数据集上每轮训练的平均时间如图 5 所示。实验结果表明 CSA-SAR 不仅在预测精度上优于其余两个方法，训练时间也更短。

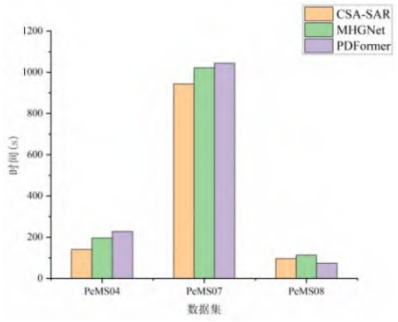
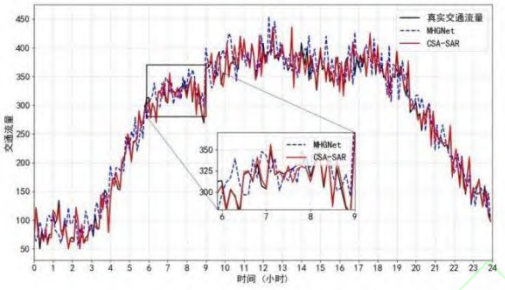


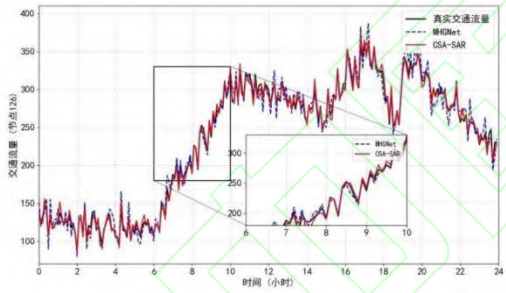
图 5　在不同数据集上每轮训练的平均时间

2.7 可视化分析

PEMS08 数据集上两个不同节点的预测结果如图 6 所示。提出的 CSA-SAR 的预测结果非常接近真实交通流量，能更准确捕捉交通流量的变化规律。尤其在早高峰和晚高峰等流量剧烈波动的时段，CSA-SAR 的预测结果与真实结果几乎一致，MHGNet 存在一定偏差，对流量峰值的预测不够精准。进一步观察局部放大区域，CSA-SAR 能更准确地预测流量数据的微小起伏和突变，表现出更强的敏感性和响应速度，MHGNet 在这些细节处会出现滞后或过平滑。CSA-SAR 不仅在整体趋势上优于 MHGNet，其预测结果也具有更高精度和鲁棒性。



(a) PEMS08中节点54流量可视化



(b) PEMS08中节点126流量可视化

图 6　交通流量预测可视化结果

3　结束语

本文提出了一种基于 CSA-SAR 的交通流量预测方法，该方法通过压缩空间注意力机制、序列聚合重分配模块和多尺度时间信息提取模块，有效提升了预测精度。具体而言，压缩空间注意力机制通过轴向压缩和细节增强，显著提升了对空间特征的建模能力；序列聚合重分配模块通过全局与局部特征的动态结合，有效解决了长期时间依赖性建模难题；多尺度时间信息提取模块进一步增强了对不同时间尺度变化的适应性。提出的 CSA-SAR 在 3 个数据集上的预测性能均能优于现有的主流交通预测方法，验证了其在捕捉交通数据复杂时空特性方面的优势。未来研究可以对更多样化的交通场景进行流量预测，以进一步提升模型通用性和稳定性。

参考文献：

[1] WANG B, ZHENG H, QIAN K, et al. Edge computing and AI-driven intelligent traffic monitoring and optimization[J]. Applied and Computational Engineering, 2024, 77: 225-230.

[2] BEN T S, HYNDMAN R J. A gradient boosting approach to the Kaggle load forecasting competition[J]. International Journal of Forecasting, 2014, 30(2): 382-394.

[3] STOCK J H, WATSON M W. Vector autoregressions[J]. Journal of Economic Perspectives, 2001, 15(4): 101-115.

[4] 张永潘,张正,徐良红,等.基于时间序列预测的冷数据压缩方法[J].南京邮电大学学报(自然科学版),2025,45(04):100-106.
ZHANG Y P, ZHANG Z, XU L H, et al. A cold data compression method based on time series prediction[J]. Journal of Nanjing University of Posts and Telecommunications (Natural Science Edition), 2025, 45(04): 100-106.

[5] 张安妮,周晓,娄立都,等.基于VAR模型的多元时间序列预测研究[J].现代计算机,2023,29(21):36-40.
ZHANG A, ZHOU X, LOU L , et al. Research on multivariate time series forecasting based on VAR model[J]. Modern Computer, 2023, 29(21): 36-40.

[6] DRUCKER H, BURGES C J C, KAUFMAN L, et al. Support vector regression machines[C]//Advances in Neural Information Processing Systems . 1997: 155-161.

[7] LI Y, YU R, SHAHABI C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(8): 12307-12319.

[8] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[C]//Proceedings of the 5th International Conference on Learning Representations. 2017: 1-14.

[9] SALEHINEJAD H, SANKAR S, BARFETT J, COLAK E, VALAEE S. Recent advances in recurrent neural networks[J]. arXiv preprint arXiv:1801.01078, 2017.

[10] SONG C, LIN Y, GUO S, et al. Spatial-temporal synchronous graph convolutional networks: A new

framework for spatial-temporal network data forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(01): 914-921.

[11] WU Z, PAN S, LONG G, et al. Graph WaveNet for deep spatial-temporal graph modeling[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(5): 1932-1944.

[12] ZHENG C, FAN X, WANG C, et al. Gman:A graph multi-attention network for traffic prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(1): 1234-1241.

[13] LI M, ZHU Z. Spatial-temporal fusion graph neural networks for traffic flow forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(5): 4189-4196.

[14] KONG W, GUO Z, LIU Y. Spatio-temporal pivotal graph neural networks for traffic flow forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(8): 8627-8635.

[15] WU M, LIN Y, JIANG T, et al. MHGNet: Multi-heterogeneous graph neural network for traffic prediction[J]. arXiv preprint arXiv:2501.03635, 2025.

[16] 杨真真,林泽龙,杨永鹏.基于双注意力图神经网络的链路预测[J].南京邮电大学学报(自然科学版),2025,45(01):106-114.
YANG Z Z, LIN Z L, YANG Y P. Link prediction based on a dual attention graph neural network[J]. Journal of Nanjing University of Posts and Telecommunications (Natural Science Edition), 2025, 45(01): 106-114.

[17] WU Z, PAN S, CHEN F, et al. A comprehensive survey on graph neural networks[J].IEEE Transactions on Neural Networks and Learning Systems, 2020,32(1): 4-24.

[18] 杨永鹏,杨震,杨真真.基于时序分解和注意力图神经网络的交通预测[J].数据采集与处理,2025,40(02):417-430.
YANG Y, YANG Z, YANG Z. Traffic prediction based on temporal decomposition and attentional graph neural networks[J]. Journal of Data Acquisition and Processing, 2025, 40(02): 417-430.

[19] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.

[20] YANG Z, CHEN Y. Cross-dimensional global interactive Transformer for traffic forecasting[J]. Digital Signal Processing, 2025, 159:1-11.

[21] YANG Y, YANG Z, YANG Z. Gated Spatial-temporal merged transformer inspired by multi-mask and dual branch for traffic forecasting[J]. IET Signal Processing, 2024, 18:1-14.

[22] YAN H, MA X, PU Z. Learning dynamic and hierarchical traffic spatiotemporal features with transformer[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(11): 22386-22399.

[23] JIANG J, HAN C, ZHAO W X, et al. Pdformer: Propagation delay-aware dynamic long-range transformer for traffic flow prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(4): 4365-4373.

[24] WAN Q, HUANG Z, Lu J, et al. Seaformer: Squeeze-enhanced axial transformer for mobile semantic segmentation[C]//The 11th International Conference on Learning Representations. 2023:1-19.

[25] HAN L, CHEN X Y, YE H J, et al. Softs: Efficient multivariate time series forecasting with series-core fusion[J]. Advances in Neural Information Processing Systems, 2024, 37: 64145-64175.

[26] LIU Z, CAI W, CHEN L. Deep Kolmogorov networks for high-dimensional nonlinear systems[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022: 7892-7900.

[27] ZAHEER M, KOTTUR S, RAVANBAKHSH S, et al. Deep sets[C]//Advances in Neural Information Processing Systems. 2017: 3391-3401.

[28] LAN S, MA Y, HUANG W, et al. DSTAGNN: Dynamic spatial-temporal aware graph neural network for traffic flow forecasting[C]//International Conference on Machine Learning. 2022: 11906-11917.